

CC-RWKV 的 Decay / Erase / Write 更新公式

① 动作参数中心化

实际动作 u_t

参考零动作 u^0

共享动作参数网络
相同世界特征 x_t^w

$$f_a(x_t^w, u) \rightarrow (\eta^a, \alpha^a, v^a, g^a)$$

$$(\delta\eta_t^a, \delta\alpha_t^a, \delta v_t^a) = f_a(x_t^w, u_t) - f_a(x_t^w, u^0)$$

$$\rho_t = \sigma(g_t^a(u_t))$$

② Decay: 调节记忆保留

自主世界衰减

$$r_t^w = c \sigma(\ell_t^w), c = 0.606531$$

$$w_t^w = \exp(-r_t^w)$$

动作调制

$$h_t^a = \text{clip}(\rho_t \odot \delta\eta_t^a, -8, 5)$$

$$r_t^{cf} = r_t^w \odot \exp(h_t^a)$$

$$w_t^{cf} = \exp(-r_t^{cf})$$

③ Erase/Edit: 定向编辑

原始 world erase

$$\Delta M^{W-e} = -(M_t \bar{k}_t)(\lambda_t \odot \bar{k}_t)^T$$

中心化动作编辑

$$e_t^a = \rho_t \odot \delta\alpha_t^a$$

$$\beta_t^a = \tanh(W_e x_t^w)$$

$$\Delta M^{a-e} = (M_t e_t^a)(\beta_t^a)^T$$

有符号 rank-1 修正: 可擦除、增强或重定向

④ Write: 写入动作效应

原始 world write

$$\Delta M^{W-w} = v_t^w (k_t^w)^T$$

中心化动作写入

$$v_t^a = \rho_t \odot \delta v_t^a$$

$$k_t^a = \tanh(W_{\ell} x_t^w)$$

$$\Delta M^{a-\ell} = v_t^a (k_t^a)^T$$

rank-1 写入: 记录实际动作相对零动作的效应

完整状态更新

$$M_{t+1} = M_t \text{Diag}(w_t^{cf}) + \Delta M^{W-e} + \Delta M^{W-\ell} + \Delta M^{a-e} + \Delta M^{a-\ell}$$

当 $u_t = u^0$ 时, 三个中心化动作残差均为零, 更新严格退化为原版 RWKV-7